

Кадарметов Дмитрий

Группа: БИВТ-ВП-23

Лабораторная работа 5.

Тема. Кластеризация объектов.

Цель: научиться группировать объекты на основе близости их свойств.

Этапы выполнения работы.

1. Определить и описать кратко предметную область. Сформулировать цель анализа, которую можно достичь на основе анализа выбранных данных с помощью изучаемых методов.
2. Подобрать множество объектов для анализа с двумя характеристиками (атрибутами) - исходная выборка.
3. Провести кластеризацию заданных объектов с помощью алгоритма k-средних:
 - 3.1 Задать число кластеров k , которое должно быть сформировано из объектов исходной выборки;
 - 3.2 Случайным образом выбирать k записей исходной выборки, которые будут служить начальными центрами кластеров;
 - 3.3 Для каждой записи исходной выборки определить ближайший к ней центр кластера;
 - 3.4 Произвести вычисление центроидов – центров тяжести кластеров;
 - 3.5 Старый центр кластера сместить в его центроид;
 - 3.6 Шаги 3 - 5 повторять до тех пор, пока выполнение алгоритма не будет прервано либо не будет выполнено условие в соответствии с заданным критерием сходимости.
4. Сделать выводы по полученным результатам анализа., включив описание полученных групп объектов.
5. Подготовить и загрузить отчет.

ОТЧЕТ О ПРОДЕЛАННОЙ РАБОТЕ

1. Предметная область – характеристика стран с точки зрения экономического развития и уровня удовлетворенности жизнью населения.

Особенности:

- 1) Комплексность – чтобы характеризовать экономическое развитие необходимо анализировать множество характеристик (ВВП, ВВП на душу населения, уровень безработицы, инфляция и др.)
- 2) Субъективность показателей – удовлетворенность жизнью является субъективным показателем, хотя зачастую тесно связанным с объективными.

Цель анализа – выделить классы стран по экономическому развитию и удовлетворенности жизнью населения на основе сходств в показателях.

2. Исходная выборка:


Страна	ВВП на душу населения (USD)	Удовлетворенность жизнью
Poland	23014	6,1
Hungary	23319	6
Greece	23966	5,8
Latvia	24194	6,2
Slovak Republic	25935	6,5
Lithuania	28407	6,4
Portugal	28969	5,8
Czechia	29801	6,9
Estonia	31855	6,5
Japan	33138	6,1
Slovenia	34026	6,5
Spain	34045	6,5
Korea	34165	5,8
France	47359	6,7
New Zealand	48531	7,3
United Kingdom	51075	6,8
Israel	53372	7,2
Germany	54291	7,3
Canada	54866	7
Finland	55127	7,9
Belgium	55536	6,8
Sweden	58529	7,3
Austria	59225	7,2

3. Построим диаграмму рассеяния:



Видно, что можно выделить два кластера ($k = 2$).

Произвольно выберем две точки – начальные центры кластеров.



Для каждой записи исходной выборки определим ближайший к ней центр кластера:

Country	Расстояние m1	от	Расстояние m2	от	Принадлежит кластеру
Poland	11151		24345,00001		1
Hungary	10846		24040,00001		1
Greece	10199		23393,00002		1
Latvia	9971,000008		23165,00001		1
Slovak Republic	8230,00003		21424		1
Lithuania	5758,000031		18952		1
Portugal	5196		18390,00002		1
Czechia	4364,000139		17558		1
Estonia	2310,000106		15504		1
Japan	1027,000044		14221,00001		1
Slovenia	139,0017626		13333		1
Spain	120,0020416		13314		1
Korea	0		13194,00003		1
France	13194,00003		0		2
New Zealand	14366,00008		1172,000154		2
United Kingdom	16910,00003		3716,000001		2
Israel	19207,00005		6013,000021		2
Germany	20126,00006		6932,000026		2
Canada	20701,00003		7507,000006		2
Finland	20962,00011		7768,000093		2
Belgium	21371,00002		8177,000001		2
Sweden	24364,00005		11170,00002		2
Austria	25060,00004		11866,00001		2


Произведем вычисление центроидов:

Номер кластера	x(new)	y(new)
1	28833,38	6,238462
2	53791,1	7,15

Вычислим ошибку:

$$E = 1147297983$$

Сместим старые центры кластера в их центроиды и вычислим новые расстояния от всех записей до центроидов:



Country	Расстояние от m1	Расстояние от m2	Принадлежит кластеру
Poland	5819,384617	30777,10002	1
Hungary	5514,384621	30472,10002	1
Greece	4867,384635	29825,10003	1
Latvia	4639,384616	29597,10002	1
Slovak Republic	2898,384627	27856,10001	1
Lithuania	426,384646	25384,10001	1
Portugal	135,6160934	24822,10004	1
Czechia	967,6156108	23990,1	1
Estonia	3021,615396	21936,10001	1
Japan	4304,615387	20653,10003	1
Slovenia	5192,615391	19765,10001	1
Spain	5211,615391	19746,10001	1
Korea	5331,615403	19626,10005	1
France	18525,61539	6432,100016	2

New Zealand	19697,61541	5260,100002	2
United Kingdom	22241,61539	2716,100023	2
Israel	24538,6154	419,100003	2
Germany	25457,61541	499,9000225	2
Canada	26032,6154	1074,90001	2
Finland	26293,61544	1335,900211	2
Belgium	26702,61539	1744,900035	2
Sweden	29695,6154	4737,900002	2
Austria	30391,6154	5433,9	2

Видно, что все записи остались в тех же кластерах, что и на предыдущей итерации, а значит алгоритм кластеризации можно завершить.

Вычислим ошибку:

$$E = 364039280,5$$

4. Выводы

- 1) Основным признаком для разделения стран на два кластера является ВВП на душу населения на уровне 35000\$, что соответствует некоторым экономическим теориям о переходе в категорию стран с "высоким доходом" (по классификации Всемирного Банка). Преодоление этого порога, как правило, связано со стабильными институтами, развитой инфраструктурой и эффективной социальной системой.
- 2) «Насыщение» благополучия: все страны во втором кластере уже достигли уровня богатства, достаточного для обеспечения базовых и многих высших потребностей. Дальнейший рост ВВП (от 47k у Франции до 59k у Австрии) не приводит к пропорциональному скачку удовлетворенности (разброс всего от 6.7 до 7.9).