

Кадарметов Дмитрий

Группа: БИВТ-ВП-23

Лабораторная работа 6.

Тема. Классификация объектов

Цель: научиться относить объекты к какому-либо классу на основе близости их свойств

Порядок выполнения работы

1. Подобрать множество объектов для анализа.
2. Определить классы объектов.
3. Разбить множество на обучающую выборку и тестирующую в соотношении 70/30.
4. Провести классификацию заданных объектов с помощью алгоритма k-NN:

– этап обучения:

- 4.1. Запомнить векторы признаков объектов и их метки классов.
- 4.2. Задать число k, которое должно быть определять количество объектов исходной выборки, участвующих в определении класса нового объекта;

- этап тестирования:

- 4.3. Для каждого объекта тестирующей выборки определить расстояние (например, Евклида) до каждого объекта обучающей выборки.
 - 4.4. Упорядочить полученные значения расстояния по возрастанию;
 - 4.5. Оценить первые k значений расстояний: определяя, объектов какого класса оказалось больше среди k отобранных значений;
 - 4.6. Отнести анализируемый объект к найденному в 3.5 классу.
5. Выполнить шаг 4 для всех объектов тестирующей выборки.
 6. Оценить качество классификации, построив матрицу несоответствий. Если точность прогноза классов ниже необходимого порога, то изменить значение k и повторить описанные выше действия для нового k.
 7. Выявить значение k, обладающее наилучшим результатом классификации.

ОТЧЕТ ПО ПРОДЕЛАННОЙ РАБОТЕ

1. Предметная область – цветы Ириса. Ирисы бывают корневищные и луковичные, делятся на две большие группы — бородатые (с волосками на лепестках, самая многочисленная группа) и безбородые (с гладкими лепестками), которые включают сибирские, японские, луизианские, калифорнийские, спуря и другие виды, а также луковичные иридодиктиумы, ксифиумы и юноны, различаются по высоте, форме цветка, окрасу и требованиям к условиям.

В рамках данной работы в качестве исходных данных используются «Ирисы Фишера» - набор данных для задачи классификации, на примере которого Рональд

Фишер в 1936 году продемонстрировал работу разработанного им метода дискриминантного анализа.

Ирисы Фишера состоят из данных о 150 экземплярах ириса, по 50 экземпляров из трёх видов — Ирис щетиный (Iris setosa), Ирис виргинский (Iris virginica) и Ирис разноцветный (Iris versicolor).

2. Гипотеза – элементы тестирующей выборки принадлежат к одному из трех классов: ирис щетиный, ирис виргинский или ирис разноцветный.
Порог точности – 85%, т.е.

$$\varepsilon = 0,85$$

Начальное значение $k = 3$.

3. Набор объектов:

petal_length	petal_width	species
1,4	0,2	setosa
1,4	0,2	setosa
1,3	0,2	setosa
1,5	0,2	setosa
...	...	...
4,7	1,4	versicolor
4,5	1,5	versicolor
4,9	1,5	versicolor
4	1,3	versicolor
...	...	...
6	2,5	virginica
5,1	1,9	virginica
5,9	2,1	virginica
5,6	1,8	virginica

4. Обучающая выборка:

№	petal_length	petal_width	species
1	1,4	0,2	setosa
2	1,7	0,4	setosa
3	1,5	0,1	setosa
4	1,4	0,3	setosa
5	4,7	1,4	versicolor
6	3,5	1	versicolor
7	4,8	1,8	versicolor
8	3,8	1,1	versicolor
9	4,4	1,2	versicolor
10	6	2,5	virginica
11	5,1	2	virginica
12	5,7	2,3	virginica
13	6,1	1,9	virginica
14	5,6	2,4	virginica

Тестирующая выборка:

№	petal_length	petal_width	species
1	1,5	0,2	setosa
2	1,7	0,5	setosa
3	4,5	1,3	versicolor
4	3,3	1	versicolor
5	5,9	2,3	virginica
6	4,9	1,8	virginica

5. Построим таблицу значений расстояний от нового объекта до каждого объекта обучающей выборки в соответствии с алгоритмом k-NN:

Расстояние	Класс
0,1	setosa
0,282842712	setosa
0,1	setosa
0,141421356	setosa
3,417601498	versicolor
2,154065923	versicolor
3,667424164	versicolor
2,469817807	versicolor
3,06757233	versicolor
5,053711507	virginica
4,024922359	virginica
4,695742753	virginica
4,904079934	virginica
4,65295605	virginica

Отсортируем строки таблицы в порядке возрастания расстояния до объектов обучающей выборки:

Расстояние	Класс
0,1	setosa
0,1	setosa
0,141421356	setosa
0,282842712	setosa
2,154065923	versicolor
2,469817807	versicolor
3,06757233	versicolor
3,417601498	versicolor
3,667424164	versicolor
4,024922359	virginica
4,65295605	virginica
4,695742753	virginica
4,904079934	virginica
5,053711507	virginica

По k ближайшим соседям ($k = 3$) определим принадлежность к классу – класс setosa.

6. Сравним метки классов, заданные изначально, с метками классов, полученными в результате анализа k ближайших соседей:

№	Исходные данные	К ближайших соседей
1	setosa	setosa
2	setosa	setosa
3	versicolor	versicolor
4	versicolor	versicolor
5	virginica	virginica
6	virginica	versicolor

Видно, что несоответствие наблюдается только в одной строке (строка №6).

7. Матрица несоответствий:

	C1	C2	C3	Prec(i)
P1	2	0	0	1
P2	0	2	1	0,666667
P3	0	0	1	1

Итоговая точность:

$$Prec = \frac{Prec_1 + Prec_2 + Prec_3}{3} = 0,888889 > \varepsilon$$

Т.к. итоговая точность превысила порог необходимой точности, то нет необходимости изменять значение k.