

Кадарметов Дмитрий

Группа: БИВТ-ВП-23

Лабораторная работа 7.

Тема. Поиск ассоциативных правил

Цель: научиться находить связи между логическими атрибутами объектов анализа в больших наборах данных.

Порядок выполнения работы

1. Подобрать множество объектов для анализа – набор транзакций.
2. Задать минимальные уровни показателей для поиска ассоциативных правил: поддержка и достоверность.
3. Найти все часто встречающиеся наборы элементов с помощью алгоритма Apriori.
4. Определить все ассоциативные правила.

Отчет по лабораторной работе

1. Определить цель проводимого анализа.
2. Представить набор транзакций в виде таблицы.
3. Указать минимальный уровень поддержки часто встречающихся наборов.
4. Для заданного набора транзакций построить методом Априори все часто встречающиеся наборы.
5. Указать минимальный уровень поддержки и оптимальный диапазон достоверности для выявления ассоциативных правил.
6. Сгенерировать все возможные правила и описать их характеристики: поддержку и достоверность. Представить в виде таблицы.
7. В качестве вывода зафиксировать все сгенерированные ассоциативные правила, с указанием их уровня достоверности.

ОТЧЕТ ПО ПРОДЕЛАННОЙ РАБОТЕ

1. Цель анализа – определить симптомы аллергии, которые чаще других появляются вместе.
2. Транзакционная база данных состоит из двух столбцов – TID и Symptoms.

TID - уникальный идентификатор, определяющий каждую транзакцию.

Symptoms – все симптомы, которые наблюдались у пациента с данным TID, у которого была выявлена аллергия.

TID	Symptoms
1	fever, back pain, shortness of breath
2	tremors, weight loss, cough, anxiety, sore throat, diarrhea
3	blurred vision, shortness of breath, runny nose, chest pain, vomiting, joint pain
4	chest pain, appetite loss, runny nose
5	depression, sweating, runny nose
6	fever, cough, appetite loss, dizziness, diarrhea, headache, weight gain

3. Установим минимальный уровень поддержки часто встречающихся наборов:

$$Sup = 2$$

4. Построим все часто встречающиеся наборы с помощью метода Apriori:

1) Присвоим значениям симптомов переменные:

Симптом	Переменная
fever	a
back pain	b
shortness of breath	c
tremors	d
weight loss	e
cough	f
anxiety	g
sore throat	h
diarrhea	i
blurred vision	j
runny nose	k
chest pain	l
vomiting	m
joint pain	n
appetite loss	o
depression	p
sweating	q
dizziness	r
headache	s
weight gain	t

Транзакционная база данных примет вид:

TID	Symptoms
1	a, b, c
2	d, e, f, g, h, i
3	j, c, k, l, m, n

4	l, o, k
5	p, q, k
6	a, f, o, r, i, s, t

2) Сформируем таблицу 1-элементных кандидатов:

Itemset	Support
a	2
b	1
c	2
d	1
e	1
f	2
g	1
h	1
i	2
j	1
k	3
l	2
m	1
n	1
o	2
p	1
q	1
r	1
s	1
t	1

3) Выделим часто встречающиеся 1-элементные наборы:

Itemset	Support
a	2
c	2
f	2
i	2
k	3
l	2
o	2

4) Из часто встречающихся 1-элементных наборов сформируем таблицу 2-х элементных кандидатов:

Itemset	Support
ac	1

af	1
ai	1
ak	0
al	0
ao	1
cf	0
ci	0
ck	1
cl	1
co	0
fi	2
fk	0
fl	0
fo	1
ik	0
il	0
io	1
kl	2
ko	1
lo	1

5) Выделим часто встречающиеся 2-х элементные наборы:

Itemset	Support
ac	1
af	1
ai	1
ao	1
ck	1
cl	1
fi	2
fo	1
io	1
kl	2
ko	1
lo	1

5. Выберем минимальный уровень поддержки и оптимальный диапазон достоверности для выявления ассоциативных правил:

$$Sup_{Min} = 20\%$$

$$Conf_{Min} = 70\%$$

6. Сгенерируем всевозможные ассоциативные правила и представим их в виде таблицы:

№	Условие	Следствие	Поддержка		Достоверность, %
			%	Кол- во	
1	cough	diarrhea	33,33333	2	100
2	diarrhea	cough	33,33333	2	100
3	chest pain	runny nose	33,33333	2	100
4	runny nose	chest pain	33,33333	2	66,66666667
5	fever	shortness of breath	16,66667	1	50
6	shortness of breath	fever	16,66667	1	50
7	fever	cough	16,66667	1	50
8	cough	fever	16,66667	1	50
9	fever	diarrhea	16,66667	1	50
10	diarrhea	fever	16,66667	1	50
11	fever	appetite loss	16,66667	1	50
12	appetite loss	fever	16,66667	1	50
13	shortness of breath	runny nose	16,66667	1	50
14	shortness of breath	chest pain	16,66667	1	50
15	chest pain	shortness of breath	16,66667	1	50
16	cough	appetite loss	16,66667	1	50
17	appetite loss	cough	16,66667	1	50
18	diarrhea	appetite loss	16,66667	1	50
19	appetite loss	diarrhea	16,66667	1	50
20	appetite loss	runny nose	16,66667	1	50
21	chest pain	appetite loss	16,66667	1	50
22	appetite loss	chest pain	16,66667	1	50
23	runny nose	shortness of breath	16,66667	1	33,33333333
24	runny nose	appetite loss	16,66667	1	33,33333333

7. Ассоциативные правила, удовлетворяющие заданным условиям:

№	Условие	Следствие	Поддержка		Достоверность, %
			%	Кол- во	
1	cough	diarrhea	33,33333	2	100
2	diarrhea	cough	33,33333	2	100
3	chest pain	runny nose	33,33333	2	100

Вывод:

Проведенный анализ показал, что:

- 1) Симптомы «Кашель» и «Диарея» являются как условиями, так и следствиями друг друга с достоверностью 100%, поэтому можно ожидать большую вероятность их взаимного появления у пациентов.
- 2) Симптом «Боль в груди» является условием симптома «Насморк» с достоверностью 100%, поэтому можно ожидать большую вероятность появления насморка у пациентов с болью в груди.